Aula 09 – Assimetria e Curtose

Desvendando a Forma das Distribuições de Dados

Nesta aula, exploraremos as medidas que nos permitem entender a forma e o pico das distribuições de dados, aprofundando nossa capacidade de análise.

Revisão: Metade da Jornada do Analista

Chegamos à metade da nossa Unidade Curricular! É o momento ideal para resgatar e consolidar todo o conhecimento que construímos até aqui. Suas anotações e atividades práticas são seu maior tesouro.

1. Medidas de Tendência Central
2. Medidas de Dispersão
3. Boxplot e Outliers
4. Pandas e NumPy
5. Manipulação de Dados

Entender esses fundamentos é crucial para desvendar a forma das distribuições de dados, o próximo passo em nossa jornada: Assimetria e Curtose!

Assimetria: O Formato da Distribuição

O que é Assimetria?

A **Assimetria** (ou Skewness) é uma medida estatística que descreve o grau de distorção de uma distribuição de dados em relação à sua simetria. Ela nos diz se os dados estão mais concentrados em um lado da média do que no outro.

Se uma distribuição é simétrica, seus lados esquerdo e direito são imagens espelhadas um do outro. A assimetria quantifica o desvio dessa simetria.

Objetivo da Assimetria:

Identificar o quanto uma distribuição tende para os valores maiores ou menores, ou se é balanceada (simétrica). Isso é crucial para entender o comportamento dos dados e tomar decisões mais precisas.

Como calcular em Python?

Utilizamos o método `.skew()` da biblioteca Pandas, aplicado diretamente a uma Série ou coluna de um DataFrame.

```
import pandas as pd

# Exemplo: df['Preco_Venda'].skew()
assimetria = df['coluna'].skew()
```

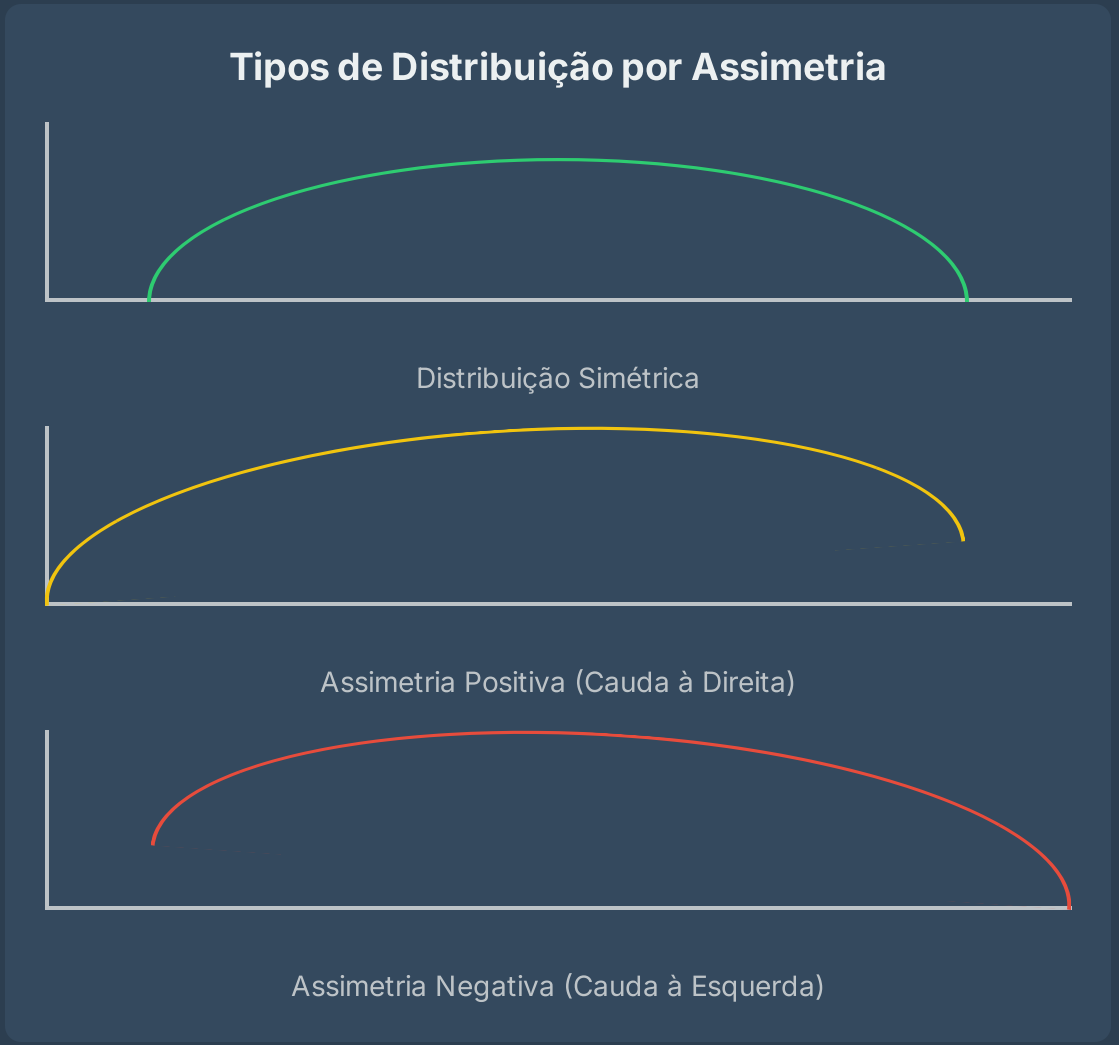

Assimetria: Guidelines de Interpretação

VALOR (SKEWNESS)	CLASSIFICAÇÃO	RELAÇÃO MÉDIA VS. MEDIANA
-0.5 a 0.5	Simétrica	A distribuição é equilibrada. A **Média** tende a ser igual ou muito próxima à **Mediana**.
> 0.5	Assimétrica Positiva	Cauda longa à direita. A **Média** tende a ser **maior** que a Mediana (valores altos "puxam" a média).
< -0.5	Assimétrica Negativa	Cauda longa à esquerda. A **Média** tende a ser **menor** que a Mediana (valores baixos "puxam" a média).

Dica do Analista: Em distribuições muito assimétricas, a **Mediana** costuma ser uma medida de tendência central mais representativa do que a Média, pois é menos afetada pelos valores extremos das caudas.

Curtose: O Pico da Distribuição

O que é Curtose?

A **Curtose** (ou Kurtosis) é uma medida estatística que indica o grau de "achatamento" ou "pico" de uma distribuição de probabilidade em relação a uma distribuição normal.

Ela nos ajuda a entender o quanto os dados estão concentrados em torno da média e a probabilidade de ocorrência de valores extremos (outliers).

Como calcular em Python?

No Pandas, utilizamos o método `.kurtosis()`. Ele retorna um valor que nos permite classificar a forma da curva.

```
import pandas as pd

# Exemplo: df['Quantidade'].kurtosis()
curtose = df['coluna'].kurtosis()
```

Os Três Tipos de Curtose

Mesocúrtica

Distribuição similar à Normal. Os dados estão distribuídos de forma equilibrada no entorno da média.

Platicúrtica

Distribuição mais "achatada". Os dados estão mais dispersos e a curva é menos pontiaguda.

Leptocúrtica

Distribuição muito "pontiaguda". Os dados estão extremamente concentrados no entorno da média.

Curtose: Guidelines de Interpretação

VALOR (K)	CLASSIFICAÇÃO	COMPORTAMENTO DOS DADOS E OUTLIERS
$2.5 \leq K \leq 3.5$	**Mesocúrtica**	Distribuição próxima da Normal. Dados distribuídos uniformemente no entorno da média. Outliers são menos comuns.
$K < 2.5$	**Platicúrtica**	Distribuição mais "achatada". Dados mais dispersos em relação à média. Outliers são comuns devido ao espalhamento.
$K > 3.5$	**Leptocúrtica**	Distribuição mais "pontiaguda". Dados extremamente concentrados no entorno da média. Outliers são muito comuns e extremos.

Dica do Analista: *Em Big Data, mesmo em distribuições Mesocúrticas, é possível encontrar outliers devido à larga escala dos dados. Sempre valide com um Boxplot!*

Curtose: Visualizando as Formas

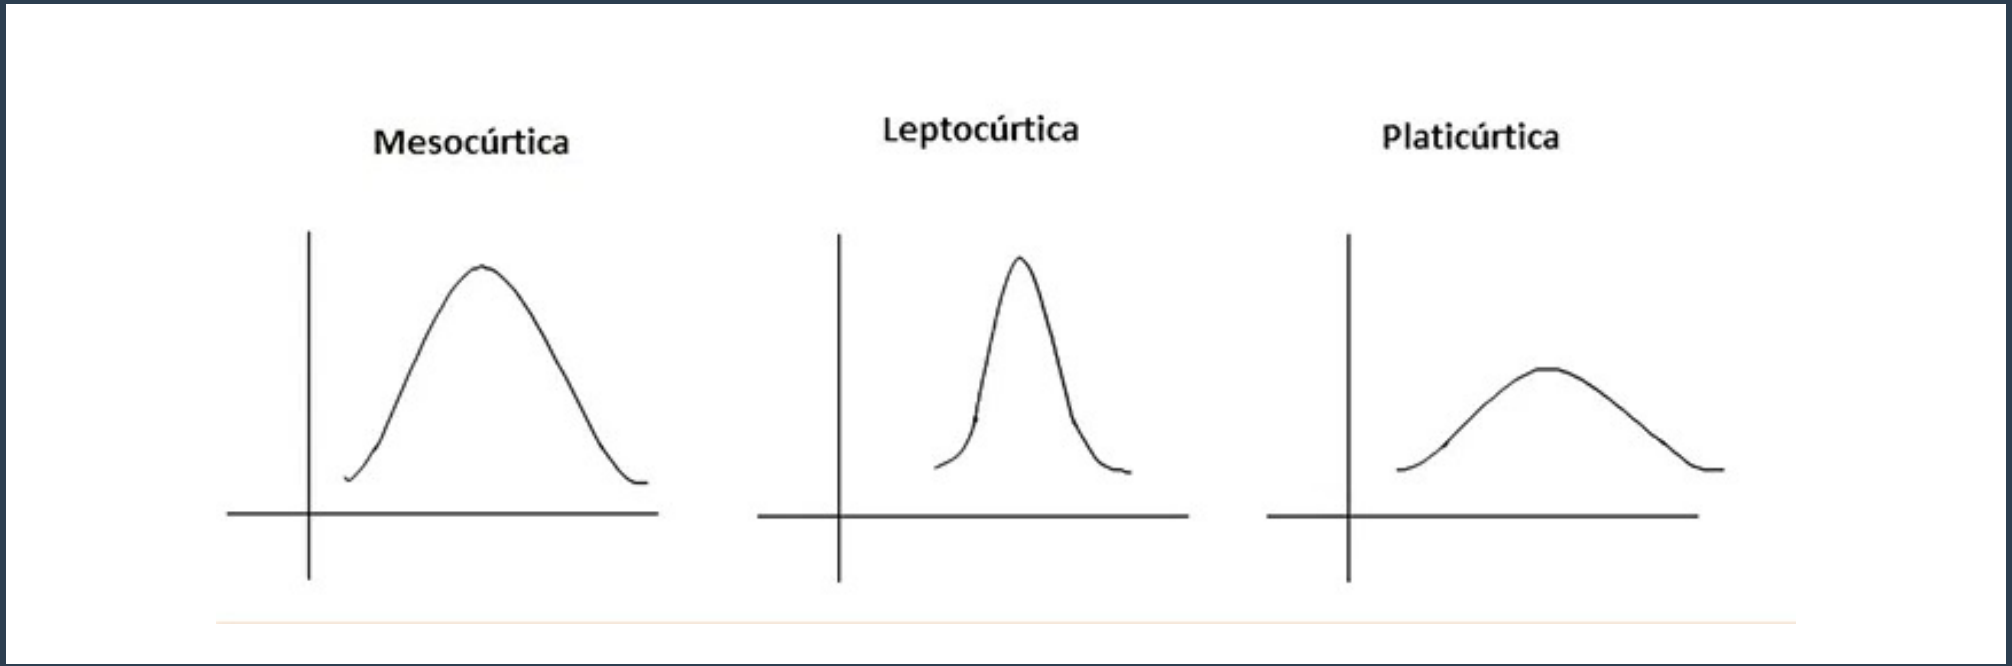

Mesocúrtica

Distribuição Normal. Dados equilibrados em torno da média.

Leptocúrtica

Pico elevado. Dados muito concentrados na média. Caudas pesadas.

Platicúrtica

Distribuição achatada. Dados mais dispersos. Caudas leves.

"A Curtose nos revela a 'intensidade' do pico e a probabilidade de encontrarmos valores extremos (outliers) na nossa análise."

Desafio: Reunião Corporativa DataOrganized

Cenário de Negócio

Você e sua equipe foram convocados para uma **reunião estratégica** com a diretoria da DataOrganized. O objetivo é apresentar um diagnóstico profundo sobre a saúde das operações de vendas.

A diretoria não quer apenas números; eles buscam **insights críticos** sobre a previsibilidade e os riscos ocultos na distribuição dos dados.

Dica: *Use uma linguagem profissional. Transforme termos técnicos como "Leptocúrtica" em explicações de valor para o negócio (ex: "alta concentração de vendas em um único patamar").*

Pauta da Reunião

- **Análise Descritiva Completa:** Apresente Média, Mediana, Moda e Desvio Padrão da variável escolhida.
- **Diagnóstico de Forma:** Calcule e interprete a **Assimetria** e a **Curtose** usando os guidelines aprendidos.
- **Visualização Crítica:** Apresente o **Boxplot** para identificar visualmente a dispersão e os outliers.
- **Raciocínio Lógico:** Proponha uma ação prática baseada no formato da distribuição encontrada.

Conclusão e Próximos Passos

Recapitulação

- **Assimetria:** Identificamos a tendência da distribuição (Simétrica, Positiva ou Negativa).
- **Curtose:** Analisamos a concentração dos dados e a probabilidade de outliers.
- **Guidelines:** Aplicamos regras práticas para classificar o formato das curvas.
- **Visão Integrada:** Unimos medidas descritivas e Boxplot para diagnósticos corporativos.

O Caminho à Frente

Com o domínio da forma dos dados, estamos prontos para explorar como as variáveis se relacionam entre si.

Próxima Aula: Aula 10

Correlação e Regressão Linear: Descobrindo as conexões e prevendo tendências na DataOrganized.

Metade da UC Concluída com Sucesso!